

Identificación de áreas con probabilidad de corresponder a asentamientos informales en Cartagena de Indias mediante IA geoespacial sobre fuentes abiertas

Nota técnica presentada como parte de la prueba aplicada al cargo de Especialista en Geoprocesamiento e IA para Soluciones Urbanas

Héctor Camilo Pérez Contreras

Junio 2026

Resumen

Documento técnico de soporte a la prueba aplicada para el cargo de Especialista en Geoprocesamiento e IA para Soluciones Urbanas, HUB Países Andinos de ONU-Hábitat (Bogotá). Describe el enfoque metodológico, las herramientas y modelos utilizados, la justificación técnica de las decisiones tomadas, la propuesta de valor, las limitaciones, los sesgos identificados, las medidas de mitigación y las recomendaciones de escalamiento. Repositorio público con código y productos en github.com/hperezc/GeoAI-specialist-prueba-tecnica-cartagena.

Índice general

Resumen ejecutivo	2
a) Enfoque metodológico	3
b) Uso de herramientas de inteligencia artificial	5
c) Justificación del enfoque seleccionado	8
d) Propuesta de valor del ejercicio	10
e) Limitaciones observadas	11
f) Análisis de posibles sesgos y riesgos asociados	12
g) Medidas de mitigación y supervisión	13
h) Recomendaciones para mejorar, adaptar o escalar el ejercicio	14
Conclusión	15

Resumen ejecutivo

El ejercicio entrega un flujo reproducible que identifica áreas con probabilidad de corresponder a asentamientos informales en el perímetro urbano oficial de Cartagena de Indias, utilizando exclusivamente fuentes geoespaciales de acceso abierto y aprendizaje automático supervisado. El producto principal es una capa raster y vectorial con la probabilidad de informalidad por celda, clasificada en cuatro niveles, y un documento técnico que sustenta las decisiones metodológicas y reconoce las limitaciones del modelo.

El núcleo metodológico fue un Random Forest de 200 árboles con calibración Platt, entrenado sobre 2,781 celdas etiquetadas (1,095 positivos y 1,686 negativos) provenientes de la capa oficial *Barrios de Cartagena* publicada por Cartagena Cómo Vamos. La validación cruzada espacial (GroupKFold sobre bloques 4×4) reportó F1 de 0.82 ± 0.12 y AUC de 0.91 ± 0.06 promediado por fold, equivalente a un AUC de 0.879 calculado sobre las predicciones out-of-fold concatenadas. La auditoría sobre el conjunto etiquetado confirmó que el modelo recupera el 91.6 % de los positivos conocidos y respeta el 99.9 % de los negativos.

Todas las decisiones técnicas se tomaron bajo dos criterios consistentes: que el flujo sea reproducible por una contraparte institucional con recursos limitados, y que el producto comunique honestamente lo que el modelo puede y no puede hacer.

a) Enfoque metodológico

El procedimiento se estructura en cuatro fases, materializadas en notebooks Jupyter independientes y trazables. Cada decisión técnica responde al objetivo del ejercicio (focalización preliminar de asentamientos informales como insumo para análisis territorial posterior) y a las restricciones reales del contexto (24 horas, fuentes abiertas, etiquetas no validadas).

La primera fase es la adquisición de información, ejecutada en `01_data_acquisition.ipynb`. El perímetro urbano oficial se tomó de la capa MGN_URB_ZONA_URBANA del Marco Geoestadístico Nacional 2024 del DANE, descargada del geoportal Colombia en Mapas del IGAC, que es la fuente cartográfica autoritativa del Estado colombiano. Se filtró la cabecera urbana principal de Cartagena (DIVIPOLA 13001, zona urbana 000) con un área de 84 km², descartando los corregimientos rurales del distrito (Bocachica, Barú, La Boquilla, Tierra Bomba y otros) que sumarían cerca de 580 km² adicionales no urbanos. Esta delimitación se prefirió sobre el polígono administrativo de OpenStreetMap porque OSM devuelve el límite distrital completo, no el suelo urbano oficial. Sobre ese perímetro se descargaron las siguientes fuentes desde Google Earth Engine: Sentinel-2 SR Harmonized 2024 (compuesto anual mediano con menos del 30 % de nubosidad y máscara SCL, a 30 m), Sentinel-1 GRD 2024 (VV y VH en órbita ascendente, a 20 m), GHS-BUILT-S 2020 del JRC, VIIRS DNB ANNUAL_V21 del Earth Observation Group, Copernicus DEM GLO-30 y WorldPop 2020 a 100 m. La red vial completa y las huellas de edificios se descargaron desde OpenStreetMap con `osmnx`. Las etiquetas de entrenamiento se construyeron desde la capa *Barrios de Cartagena* publicada por Cartagena Cómo Vamos (CCV) en su portal Open Data sobre ArcGIS Hub, que contiene los 213 polígonos oficiales de los barrios de la ciudad con nombre, Unidad Comunera de Gobierno y localidad. Se seleccionaron 33 barrios informales consolidados (sub-sectores de Olaya Herrera, Nelson Mandela, El Pozón, Boston, San Francisco, Loma Fresca, Lo Amador, Fredonia, Henequén, Las Palmeras, Albornoz, Villas Barraza/Fanny/Rubia/Hermosa/Sandra, Nueva Jerusalén, Nuevo Paraíso, Nuevo Porvenir, Juan XXIII, Las Gaviotas, entre otros) como positivos, y 40 barrios formales (Centro, Getsemaní, San Diego, Bocagrande, Castillogrande, Manga, Pie de la Popa, Crespo, Marbella, Cabrero, Alto Bosque, Blas de Lezo, Los Cerros, La Castellana, Daniel Lemaitre, Torices, El Bosque, Nuevo Bosque, entre otros) como negativos. La mezcla de barrios formales altos con barrios formales populares consolidados es deliberada: ofrece al modelo una frontera real entre informalidad y formalidad modesta, y no solo el contraste fácil con sectores residenciales de clase alta.

La clasificación de cada barrio como informal o formal no es una asignación subjetiva, sino que se sustenta en literatura urbana y socioeconómica verificable sobre Cartagena. La referencia central consultada es el trabajo de Pérez Valbuena y Salazar Mejía (2007), *La pobreza en Cartagena: un análisis por barrios*, Documento de Trabajo sobre Economía Regional No. 94 del Centro de Estudios Económicos Regionales del Banco de la República, que analiza la distribución espacial de la pobreza en Cartagena combinando indicadores de ingreso, Necesidades Básicas Insatisfechas, educación e informalidad laboral, y reporta una focalización clara de la pobreza en las laderas del Cerro de La Popa y los barrios adyacentes a la Ciénaga de la Virgen, donde se concentran la mayoría de los positivos del modelo.

Esta referencia se complementó con dos fuentes adicionales para cubrir barrios no incluidos en el estudio de 2007, ya sea por corresponder a desarrollos posteriores o por quedar fuera de su muestra: los informes anuales de Cartagena Cómo Vamos, que monitorea calidad de vida por barrio y Unidad Comunera de Gobierno, y el Plan de Ordenamiento Territorial vigente del Distrito de Cartagena, que identifica los sectores de tratamiento de mejoramiento integral asociados a asentamientos informales consolidados. La selección de negativos sigue la misma lógica e incorpora deliberadamente tanto barrios formales altos como barrios formales populares consolidados reconocidos por el POT y por la estratificación socioeconómica del DANE, de modo que el conjunto de entrenamiento le permita al modelo distinguir entre informalidad estructural y formalidad popular consolidada, y no solo entre informalidad y residencial de clase alta. La revisión por un panel territorial local antes de cualquier despliegue operativo, descrita en el apartado g), es el mecanismo formal previsto para auditar y actualizar esta selección con conocimiento experto del terreno.

La segunda fase corresponde al preprocesamiento y la generación de variables, ejecutada en `02_feature_engineering.ipynb`. Se construyó una grilla regular de $100\text{ m} \times 100\text{ m}$ en EPSG:32618 (WGS 84 / UTM 18N) sobre la cabecera urbana, que es la unidad de análisis del modelo. Esta resolución se eligió por tres razones técnicas que se discuten en el apartado c): coincide con la resolución nativa de GHS-BUILT y WorldPop, ofrece una granularidad apropiada para focalización a escala barrial sin sugerir falsa precisión a nivel de píxel, y mantiene un volumen computacional manejable (9,004 celdas iniciales, 8,902 tras el filtro de urbanidad). Por cada celda se calcularon 25 variables predictoras: reflectancias Sentinel-2 (B2, B3, B4, B5, B6, B7, B8, B8A, B11, B12) e índices derivados (NDVI, NDBI, NDWI, BSI), backscatter Sentinel-1 (VV, VH) y la diferencia VH–VV en dB como métrica de heterogeneidad superficial, fracción construida GHS-BUILT, radiancia VIIRS, elevación y pendiente derivada por el método de Horn desde el DEM, densidad poblacional WorldPop, densidad de vías OSM (km por celda), distancia desde el centroide a la vía primaria/secundaria más cercana, número de edificios OSM, área total, área media y desviación del área de los edificios, y compacidad media ($4\pi \cdot \text{área} / \text{perímetro}^2$). Tras un filtro de urbanidad (celdas con superficie construida superior a 1 m^2 o presencia de población o de edificios OSM) se conservaron 8,902 celdas. Las etiquetas se sellaron sobre la grilla por intersección del centroide con los polígonos CCV, resultando en 1,095 celdas positivas y 1,686 negativas.

La tercera fase corresponde al modelo, en `03_modeling.ipynb`. Se entrenó un Random Forest con 200 árboles, ponderación por clase (`class_weight="balanced"`), `min_samples_leaf=2` y semilla fija para reproducibilidad. La salida se envolvió en un `CalibratedClassifierCV` con calibración Platt (sigmoid) y validación interna de 3 folds para que las probabilidades emitidas sean interpretables como tales y no como simples scores. La validación cruzada para reportar métricas se hizo con `GroupKFold` sobre 16 bloques geográficos (cuadrícula 4×4 sobre el área de estudio), una estrategia que garantiza que cada fold de prueba contenga celdas geográficamente distintas a las del entrenamiento y evita el data leakage espacial que arrastra el split aleatorio típico. Las métricas resultantes fueron F1 de 0.82 ± 0.12 , AUC de 0.91 ± 0.06 (promediado por fold) o equivalentemente 0.879 calculado sobre las predicciones out-of-fold concatenadas, precisión de 0.83 y recall de 0.82.

Ambas formas de calcular el AUC son convenciones legítimas en la literatura y resultan consistentes entre sí; las curvas ROC y Precision-Recall correspondientes (in-sample versus out-of-fold espacial) se incluyen en el notebook `03_modeling.ipynb` para evidenciar el comportamiento real del modelo frente a su ajuste sobre los datos vistos. La auditoría posterior sobre el conjunto etiquetado completo arrojó 91.6 % de positivos correctos, 99.9 % de negativos correctos, solo 2 falsos positivos y 92 falsos negativos. La predicción se aplicó a las 8,902 celdas (etiquetadas y no etiquetadas), y la clasificación en cuatro niveles se hizo con umbrales absolutos de probabilidad (Baja < 0.40 , Media $0.40-0.60$, Alta $0.60-0.75$, Muy alta ≥ 0.75) en lugar de percentiles, para que cada nivel sea interpretable como confianza real del modelo y no como ranking relativo sobre la distribución observada.

La cuarta fase, `04_mapping.ipynb`, genera los productos cartográficos finales: un GeoTIFF de probabilidad continua, un GeoPackage de celdas clasificadas (8,902 celdas individuales con su probabilidad y nivel), un GeoPackage adicional de zonas disueltas (las celdas contiguas de la misma clase se agrupan en polígonos continuos con estadísticas agregadas de probabilidad y área), un GeoJSON simplificado para uso web, y dos mapas estáticos en PDF y PNG (probabilidad continua y clasificación discreta), con leyenda, escala, contexto cartográfico CartoDB Positron y un disclaimer explícito sobre la naturaleza preliminar del producto.


La revisión técnica experta no se materializó dentro del ejercicio de 24 horas, lo cual se reconoce explícitamente. El diseño metodológico, sin embargo, está pensado para incorporar esa revisión en tres momentos del ciclo de vida del producto: una auditoría de las etiquetas iniciales por un panel territorial (técnicos de la Secretaría de Planeación de Cartagena, academia local, organizaciones comunitarias) antes de un eventual reentrenamiento, un muestreo dirigido en campo sobre celdas de probabilidad alta fuera de los polígonos de entrenamiento para verificar generalización geográfica, y una validación final por trabajo de campo orientado a las clases Muy alta y Alta para construir matrices de confusión sobre verdad-terreno y refinar el modelo en iteraciones sucesivas.

b) Uso de herramientas de inteligencia artificial

El enfoque corresponde a aprendizaje automático supervisado clásico aplicado como clasificación binaria sobre datos tabulares por celda. No se utilizó deep learning ni visión por computador en sentido estricto (segmentación a nivel de píxel), por razones que se justifican en el apartado siguiente. El modelo es un Random Forest envuelto en un calibrador Platt, implementado con scikit-learn.

Las herramientas técnicas del flujo son las siguientes. Python 3.10+ como lenguaje principal. Google Earth Engine, mediante su API de Python y geemap, para el procesamiento satelital a escala (Sentinel-1, Sentinel-2, VIIRS, GHS-BUILT, Copernicus DEM, WorldPop). GeoPandas, Rasterio, Shapely y pyproj para la manipulación geoespacial local. OSMnx para la extracción de la red vial y las huellas de edificios desde OpenStreetMap. scikit-learn para Random Forest, calibración Platt y validación cruzada espacial con GroupKFold. scikit-image disponible para texturas GLCM (no incorporado en el conjunto final, mencionado como mejora futura). Matplotlib y contextily para la cartografía estática. El entregable se compone de

Probabilidad de asentamientos informales en Cartagena de Indias
Modelo Random Forest sobre fuentes abiertas — junio 2026



Producto preliminar. Requiere validación experta y de campo. No corresponde a delimitación oficial de asentamientos informales.
 Fuentes: Sentinel-2/1 (Copernicus), GHS-BUILT (JRC), VIIRS (NOAA), Copernicus DEM, WorldPop, OpenStreetMap. Autor: Héctor C. Pérez · ONU-Habitat (prueba técnica).

Figura 1: Mapa de probabilidad continua de asentamientos informales en Cartagena de Indias. Las zonas de color más intenso corresponden a mayor probabilidad. Los polígonos rojos punteados son las etiquetas positivas (barrios informales reconocidos) y los verdes son las etiquetas negativas (barrios formales reconocidos), todos provenientes del shapefile oficial de Cartagena Cómo Vamos.

Clasificación por niveles de probabilidad — Cartagena de Indias




Figura 2: Clasificación discreta del producto en cuatro niveles de probabilidad. La distribución resultante (Baja 49.5 %, Media 25.7 %, Alta 15.5 %, Muy alta 9.3 %) es consistente con estimaciones independientes de Cartagena Cómo Vamos sobre la proporción del territorio en condiciones de informalidad o precariedad.

cuatro notebooks Jupyter (.ipynb), que combinan código ejecutable, documentación en celdas Markdown y los outputs preservados de la última corrida, junto con los módulos auxiliares de utilidades en la carpeta src/.

Las 25 variables predictoras se organizan en seis familias. Las espectrales de Sentinel-2 capturan diferencias en cobertura vegetal (NDVI), intensidad de construcción (NDBI), presencia de agua (NDWI) y exposición de suelo (BSI), todas características visuales que se asocian con la informalidad. Las de radar Sentinel-1 detectan densidad y geometría de construcciones bajo cualquier condición de cobertura nubosa, una propiedad valiosa en el Caribe colombiano. La fracción construida GHS-BUILT es un indicador estructural y consistente de presencia urbana. La radiancia nocturna VIIRS funciona como proxy de acceso a servicios eléctricos, sobre la hipótesis razonable de que los asentamientos informales tienden a iluminación más baja o irregular. Las topográficas (elevación y pendiente desde el DEM) capturan el hecho documentado de que en Cartagena los asentamientos informales se concentran en pendientes pronunciadas de la Loma del Marión, el Cerro de La Popa y laderas adyacentes. Las estructurales OSM (densidad y geometría de vías, número, área media y desviación del área de los edificios, compacidad media) capturan la irregularidad morfológica y la heterogeneidad del tejido edificado, características típicas de la informalidad.

El proceso de modelado siguió criterios estándares de buenas prácticas: división de las etiquetas para validación cruzada espacial con bloques geográficos, ponderación por clase para el desbalance leve (1,095 vs 1,686), entrenamiento sobre el conjunto etiquetado completo después de validar, calibración Platt para que las probabilidades de salida tengan interpretación, y umbrales absolutos para la clasificación discreta. Random Forest no requiere normalización de variables, lo que permite mantenerlas en sus unidades originales.

c) Justificación del enfoque seleccionado

La elección de Random Forest sobre features tabulares por celda se sostiene en cinco criterios ponderados explícitamente: precisión esperada, eficiencia computacional, disponibilidad de etiquetas, costo técnico de implementación y aplicabilidad al contexto institucional.

Sobre la primera alternativa descartada, las arquitecturas de segmentación semántica (U-Net, DeepLab) y los modelos fundacionales geoespaciales con fine-tuning (Prithvi-EO de IBM/NASA, Clay) requieren volúmenes de etiquetas y tiempos de entrenamiento incompatibles con la restricción del ejercicio (24 horas y etiquetas no validadas), además de infraestructura GPU. Su precisión potencial es superior, pero el costo de implementación y el riesgo de sobreajuste sobre etiquetas ruidosas no justifican esa precisión adicional para un producto pensado como insumo preliminar de focalización. Se mencionan, sin embargo, como ruta de mejora en el apartado h).

Sobre la segunda alternativa, los modelos de gradient boosting (XGBoost, LightGBM) son competitivos con Random Forest en este tipo de tareas tabulares y a veces marginalmente superiores. Se descartaron por ofrecer menor interpretabilidad directa por feature importance y porque la diferencia de precisión esperada sobre etiquetas no validadas no compensa esa pérdida. Se incluyen también como variante

a explorar en versiones posteriores.

Sobre la tercera alternativa, el clustering no supervisado (K-Means, ISODATA) sobre features espectrales no requiere etiquetas pero produce particiones difíciles de mapear a la categoría informal/formal sin postprocesamiento humano, y no aprovecha la información de los barrios CCV disponibles.

Random Forest fue preferido por la combinación de cinco propiedades. Primero, manejo robusto de etiquetas limitadas y potencialmente ruidosas: el esquema de bagging y la diversidad de árboles débilmente correlacionados es notablemente resistente al sobreajuste sobre etiquetas con ruido, condición presente aquí dado que las etiquetas CCV son polígonos de barrio enteros sin distinguir subáreas formales dentro de barrios informales o viceversa. Segundo, manejo natural de variables heterogéneas en escala: las 25 features mezclan reflectancias (0-1), distancias en metros (decenas de miles), conteos enteros, grados de pendiente, radiancia nocturna y razones adimensionales, todo lo cual Random Forest procesa sin normalización. Tercero, interpretabilidad por feature importance, que permite construir argumentos defendibles ante revisores no técnicos sobre qué características llevan al modelo a clasificar una celda como probable asentamiento informal. Cuarto, eficiencia computacional acorde a un contexto institucional con recursos limitados: el modelo entrena en segundos sobre los datos disponibles y se ejecuta en CPU estándar, lo que permite que otras oficinas del HUB Andino o equipos técnicos municipales puedan replicar el flujo sin infraestructura especializada. Quinto, honestidad técnica del producto: el balance honesto del modelo (precisión razonable, no sobresaliente) se traduce en un producto que se presenta correctamente como herramienta de focalización preliminar y no como sistema automatizado de decisión, lo que reduce el riesgo de uso indebido por parte de actores receptores.

La resolución de análisis de 100 m $\times$ 100 m se sostiene en cuatro argumentos técnicos. Coincide con la resolución nativa de GHS-BUILT y WorldPop, lo cual significa que estas dos fuentes auxiliares se samplean sin remuestreo y el valor de la celda corresponde directamente al píxel original del producto, evitando artefactos de interpolación. Es la escala apropiada al propósito del ejercicio, que es focalizar trabajo de campo y priorizar inversión pública, no identificar edificios individuales. Una celda de 100 $\times$ 100 m equivale aproximadamente a una manzana urbana, que es la unidad operativa con la cual trabajan las secretarías municipales y las agencias humanitarias. Mantiene un volumen computacional manejable: 9,004 celdas para el área de estudio permiten entrenar, validar e iterar en tiempo de cómputo razonable, mientras que una resolución de 10 m daría 840,000 celdas (95 veces más) y obligaría a infraestructura distinta. Adicionalmente, trabajar a 10 m sobre etiquetas barriales y features con incertidumbre intrínseca produciría falsa precisión, porque el modelo no distingue al nivel de píxel lo que sus insumos no le permiten distinguir.

El análisis se basa en imágenes satelitales transformadas en datos estructurados por celda. Aunque el insumo crudo es imagen óptica y radar, todo el modelado opera sobre features tabulares derivadas. Esta es una decisión consciente: reducir la dimensionalidad de la imagen a variables con sentido urbano antes de modelar, ganando interpretabilidad y eficiencia a costa de la precisión marginal que daría un enfoque puramente convolucional.

Una observación adicional sobre las features finales. El modelo final mostró una concentración importante de importancia en `dist_via_principal_m` (43 %), seguida por `area_media_m2`, `B11`, `poblacion`, `VIIRS`, `B8` y otras con importancias entre 3 y 7 %. La distancia a vía principal captura una señal real (los asentamientos informales tienden a estar más alejados de la red vial primaria), pero también es un proxy parcialmente geográfico que debe auditarse al escalar el flujo a otras ciudades, donde la estructura vial puede comportarse distinto.




Figura 3: Importancia relativa de las 25 variables predictoras según el Random Forest entrenado. El perfil mezcla variables estructurales (distancia a vías, área media de edificios, fracción construida), espectrales (B11 SWIR1, B8 NIR, NDVI), de iluminación (VIIRS) y poblacionales (WorldPop), lo que sugiere que el modelo no aprende un único proxy sino que combina información de múltiples dimensiones.

d) Propuesta de valor del ejercicio

El valor del modelo, comparado con un escenario sin herramientas analíticas, se manifiesta en cuatro dimensiones operativas.

La primera es la focalización del trabajo de campo. Un censo o caracterización tradicional de asentamientos informales en Cartagena (84 km² urbanos) exige recorridos extensos, fotointerpretación manual y verificación parcela por parcela,

con costos que escalan linealmente con el área. El producto entrega en pocas horas un mapa preliminar que permite a un equipo concentrar el 80 % de su esfuerzo en el 25 % del territorio (clases Alta y Muy alta) donde el riesgo de informalidad es alto, sin renunciar al examen experto en esas zonas. Para una Secretaría de Planeación con presupuesto restringido, eso significa la diferencia entre cubrir la ciudad y dejarla sin diagnosticar.

La segunda es la trazabilidad y reproducibilidad del proceso. Todo el flujo queda documentado en código versionado en repositorio público. A diferencia de un análisis hecho en una herramienta GIS de escritorio (donde las decisiones quedan en la memoria del analista y se pierden con la rotación de personal), este flujo es auditable, refutable y mejorable por terceros. Una nueva persona del equipo puede replicar el resultado en otra ciudad cambiando un parámetro de configuración (el polígono administrativo de entrada y las listas de barrios etiquetados).

La tercera es la optimización del uso de recursos públicos. En presupuestos restringidos, la focalización inteligente reduce el gasto en intervenciones mal dirigidas. Si se quiere ampliar cobertura de servicios básicos, mejorar movilidad o priorizar regularización urbana, el mapa indica dónde el problema es más probable y permite construir argumentos cuantitativos (cuántas hectáreas afectadas, población estimada, pendiente promedio del terreno) para sustentar decisiones presupuestales.

La cuarta es la escalabilidad regional. El mismo flujo, sustituyendo el polígono administrativo y los polígonos de etiquetas, puede correrse sobre Barranquilla, Santa Marta, Riohacha, Guayaquil, Lima, La Paz u otras ciudades del HUB Países Andinos. Eso convierte el ejercicio en una plantilla replicable y no en un análisis puntual de Cartagena.

Es importante señalar lo que el producto no aporta. No caracteriza condiciones internas del asentamiento (tipología constructiva, acceso a servicios, tenencia de suelo, hacinamiento). No detecta dinámicas temporales finas sin datos multitemporales adicionales. Y no sustituye el conocimiento local que reside en las comunidades y en los equipos territoriales. Su rol es complementario y precursor, no sustitutivo.

e) Limitaciones observadas

Se reportan con honestidad técnica las restricciones del ejercicio, agrupadas por familia.

Las limitaciones metodológicas. Las etiquetas no están validadas en campo. El conjunto positivo proviene de la capa CCV de barrios informales consolidados, pero CCV no es un catastro: marca el barrio completo sin distinguir subáreas formales dentro de un barrio informal ni asentamientos informales aislados dentro de un barrio formal. El modelo aprende esa simplificación y la propaga al producto. La definición binaria (informal/formal) simplifica un fenómeno que en realidad es gradual: existe una franja amplia de barrios populares formalizados con condiciones precarias que el modelo puede ubicar ambiguamente entre clases Media y Alta. La validación cruzada espacial con bloques 4×4 es robusta para detectar leakage, pero el número efectivo de folds informativos puede ser menor cuando algunos bloques tienen pocas etiquetas.

Las limitaciones técnicas. La resolución de 100 m es adecuada para focalización barrial pero no para discriminar tipologías muy intercaladas con tejido formal, que pueden quedar mezcladas dentro de una misma celda. Las texturas GLCM, disponibles como utilidad en el código, no se incorporaron en el conjunto final por restricción de tiempo. El tratamiento de valores faltantes se hizo por imputación de mediana sobre las features, lo que es estándar pero no óptimo; métodos condicionales podrían marginalmente mejorar la calidad.

Las limitaciones operativas. Veinticuatro horas son suficientes para entregar un flujo defendible pero no para iterar múltiples configuraciones del modelo, ensayar arquitecturas alternativas (XGBoost, foundation models con transfer learning) o ejecutar campañas de validación. Tampoco para incorporar conocimiento territorial de expertos locales en la definición fina de etiquetas.

Las limitaciones de los datos. La cobertura de OpenStreetMap no es uniforme: barrios formales y zonas turísticas están mejor mapeados que asentamientos informales, lo que introduce un sesgo que se discute en el apartado siguiente. El GHS-BUILT más reciente disponible es de 2020 y puede subestimar asentamientos consolidados entre 2020 y 2024. VIIRS satura en áreas comerciales muy iluminadas, lo que comprime la información en el extremo alto del rango dinámico. Sentinel-2 se descargó a 30 m (su resolución nativa es 10 m) para mantenerse bajo el límite de 50 MB de descarga directa de GEE; esto es marginal para el análisis a 100 m pero limita usos posteriores que requieran mayor detalle.

f) Análisis de posibles sesgos y riesgos asociados

El producto se diseñó con perspectiva *trust by design*: los riesgos del modelo se identificaron desde la fase metodológica, no como apéndice posterior, y la elección de fuentes, features y umbrales se hizo con conocimiento explícito de esos riesgos. Se distinguen tres categorías de sesgos y se examinan los impactos diferenciales según el tipo de error.

Sobre los sesgos derivados de las fuentes de información. OpenStreetMap es un proyecto colaborativo cuya densidad de mapeo refleja la actividad de la comunidad mapeadora local, históricamente sobreproducida en áreas centrales, turísticas o académicas y subrepresentada en periferias urbanas y asentamientos informales. Las variables derivadas de OSM (número de edificios, área media, compacidad) tienden a estar artificialmente bajas en zonas informales. El modelo aprende a asociar ausencia de mapeo OSM con alta probabilidad de informalidad, lo cual es funcional para la tarea pero por una razón equivocada: es correlación, no causalidad. Esto se confirma en el feature importance final, donde las variables OSM aportan menos de lo esperado individualmente pero el patrón colectivo es informativo. Sobre el sesgo temporal, GHS-BUILT 2020 y WorldPop 2020 son los productos consolidados más recientes disponibles. Asentamientos formados entre 2020 y 2024 pueden estar subrepresentados. Sobre el sesgo de definición, el producto operacionaliza informalidad como la combinación de patrón espectral, irregularidad estructural, baja iluminación nocturna y déficit relativo de equipamientos OSM. Eso captura algunas dimensiones de la informalidad pero no otras: titulación irregular del suelo, ausencia

de servicios formales o autogestión comunitaria del territorio no son observables desde el satélite.

Sobre los sesgos derivados del diseño y entrenamiento del modelo. El sesgo geográfico de las etiquetas se mitigó deliberadamente con la fuente CCV: los positivos cubren norte (Olaya, Mandela, Pozón, Boston, San Francisco, La Popa), centro-orienté y sur (Henequén, Las Palmeras, Villas, Nueva Jerusalén), y los negativos cubren península sur, centro amurallado, norte costero, residencial medio (Blas de Lezo, Los Cerros, La Castellana) y formal popular consolidado (Daniel Lemaitre, Torices, El Bosque). Esta distribución reduce el riesgo de que el modelo aprenda “norte = informal, sur = formal”. Sin embargo, tipologías de informalidad no incluidas en el listado CCV (por ejemplo La Boquilla en su sector palafítico, o asentamientos rurales del distrito) quedan subrepresentadas. El sesgo de muestreo de negativos persiste parcialmente: aunque se incluyeron 40 barrios formales de distintos estratos, el conjunto tiende a barrios consolidados y deja menos contraste con barrios populares en transición. El desbalance de clases es leve (1,095 positivos vs 1,686 negativos) y se compensó con `class_weight="balanced"`.

Sobre los sesgos derivados de la interpretación de resultados. El riesgo de uso descontextualizado del mapa es real. Una clasificación “Muy alta” puede ser leída por actores externos sin la formación adecuada como diagnóstico definitivo, dando lugar a decisiones operativas que estigmaticen el territorio, dificulten la inversión privada legítima o sustenten decisiones de desalojo. El producto va acompañado de un disclaimer explícito en el mapa final y en este documento sobre su naturaleza preliminar. Un segundo riesgo es la inacción: si los resultados se usan para confirmar lo que ya se sabe pero no se traducen en intervenciones positivas (regularización, servicios, vivienda), el producto reproduce el problema en lugar de mitigarlo.

Sobre los impactos diferenciales según el tipo de error. Un falso positivo (celda clasificada como alta probabilidad sin serlo) genera estigmatización del territorio, sub-inversión privada potencial y riesgo de discriminación administrativa contra residentes formales. Un falso negativo (asentamiento informal no detectado) invisibiliza necesidades, excluye a la población de programas de regularización y servicios, y perpetúa inequidades territoriales. La elección del umbral de probabilidad determina el balance entre ambos errores. Para un producto pensado como insumo de priorización (no de decisión final) se recomienda privilegiar el recall sobre la precisión: es preferible incluir falsos positivos que excluir falsos negativos, porque la verificación humana posterior puede descartar los primeros pero no rescatar lo que el modelo ya invisibilizó. La auditoría reportada (recall 91.6 %, precisión 99.9 % sobre etiquetadas) refleja esta priorización.

g) Medidas de mitigación y supervisión

Las medidas propuestas se organizan en tres momentos del ciclo de vida del producto.

Antes del despliegue. La primera medida es una auditoría de etiquetas por un panel territorial de tres a cinco personas con conocimiento del terreno (técnicos de la Secretaría de Planeación de Cartagena, académicos urbanos de la Universidad de Cartagena o el Tecnológico de Bolívar, líderes comunitarios). El panel debe revisar

las listas de barrios CCV usadas como positivos y negativos, agregar o quitar barrios según conocimiento local actualizado, y dejar registro de los criterios aplicados. La segunda es un análisis de fairness territorial: aplicar el modelo entrenado sobre un conjunto de verificación geográficamente diverso y reportar métricas de desempeño desagregadas por zonas (norte, centro, sur, oriente, isla). Si el F1 cae sustancialmente en alguna zona, no desplegar hasta entender la causa. La tercera es una *model card* que documente explícitamente datos de entrenamiento, métricas desagregadas, limitaciones conocidas, riesgos identificados y usos contraindicados; es la práctica estándar de IA responsable y se acompaña como anexo cuando el producto se comparte fuera del equipo técnico.

Durante el uso operativo. La cuarta medida es validación humana obligatoria antes de cualquier decisión. Ninguna intervención pública debería derivarse directamente del modelo. El flujo recomendado es modelo → priorización de zonas → trabajo de campo → diagnóstico final → decisión de política. La quinta es la incorporación del producto a un tablero institucional con feedback loop: los usuarios deben poder marcar celdas como “confirmado” o “incorrecto”, alimentando un registro que sirve para reentrenamiento periódico. Cada validación humana es información que mejora el modelo. La sexta es un disclaimer permanente en todas las visualizaciones del producto, sin excepción, clarificando su naturaleza preliminar, las fuentes utilizadas y el rol obligatorio de la validación de campo. La séptima es una restricción de difusión: productos a granularidad de celda no deberían publicarse abiertamente con coordenadas precisas si pueden ser usados para acciones contra los residentes. La difusión pública debería operarse a agregaciones mayores (barrio, sector, comuna) mientras los productos finos quedan disponibles solo para entes públicos con uso justificado.

Iteraciones futuras. La octava medida es el reentrenamiento periódico, calendarizado cada doce o dieciocho meses, con etiquetas validadas en campo acumuladas en el ciclo anterior. La novena es la ampliación a clasificación multiclase (no informal / informal incipiente / informal consolidado) para reflejar el gradiente real de la informalidad y no forzar una decisión binaria. La décima es la integración con datos comunitarios: habilitar capas de información generada por organizaciones locales (mapeo participativo, OpenStreetMap dirigido a sectores informales) para reducir el sesgo de cobertura OSM y mejorar la representación territorial.

h) Recomendaciones para mejorar, adaptar o escalar el ejercicio

Mejoras técnicas concretas. Incorporar Sentinel-2 multitemporal: construir compuestos estacionales (seco y húmedo) y derivar variables de variabilidad temporal del NDVI y el NDBI; esto es particularmente útil en el Caribe, donde la estacionalidad altera fuertemente la firma espectral. Probar XGBoost o LightGBM como modelo alternativo, validando si la ganancia de precisión justifica la pérdida de interpretabilidad y reportando una comparación honesta. Explorar fine-tuning de foundation models geospaciales (IBM/NASA Prithvi-EO, Clay) sobre un conjunto pequeño de etiquetas validadas: estos modelos pre-entrenados sobre cientos de millones de píxeles satelitales pueden requerir tan solo decenas a centenas de

muestras de fine-tuning para producir segmentación competitiva. Integrar Microsoft Building Footprints o Google Open Buildings para subsanar el sesgo de cobertura OSM: ambos son productos abiertos derivados de IA y cubren toda Colombia. Calcular texturas GLCM sobre Sentinel-2 NIR y SWIR para capturar irregularidad estructural a escala fina. Cambiar la validación cruzada de bloques geométricos por bloques de barrio o comuna, que son más representativos de cómo el producto será utilizado por la administración local.

Mejoras de proceso. Implementar pipeline reproducible con DVC o similar, versionando no solo el código sino también los datos crudos y los modelos, asegurando reproducibilidad bit-exact ante cualquier auditoría. Configurar CI/CD del flujo geoespacial para que corra automáticamente sobre cualquier nuevo conjunto de datos (por ejemplo, otra ciudad) con verificaciones automáticas de integridad. Producir documentación bilingüe español-inglés del repositorio y la nota técnica, facilitando la replicación por equipos de otras agencias del Sistema ONU en la región.

Adaptación y escalamiento a otras ciudades intermedias de América Latina. El flujo está diseñado para ser portable. Los pasos para replicarlo en otra ciudad (Barranquilla, Riohacha, Guayaquil, Trujillo, Santa Cruz de la Sierra) son sustituir el polígono administrativo de entrada por el de la nueva ciudad, generar un conjunto inicial de etiquetas locales con apoyo de un equipo territorial (mínimo treinta a cincuenta polígonos positivos y veinte a treinta negativos confiables), reentrenar el modelo manteniendo la arquitectura y los hiperparámetros, y validar y publicar el producto siguiendo el protocolo de mitigación descrito en el apartado g). Las condiciones que deben evaluarse antes de replicar son: presencia de imágenes Sentinel-2 con cobertura nubosa manejable (en algunas regiones amazónicas o pacíficas la cobertura útil es muy limitada y conviene priorizar Sentinel-1), cobertura OSM suficiente para que las variables derivadas tengan sentido (en ciudades pequeñas, OSM puede estar muy subdesarrollado), y disponibilidad institucional para acompañar el ejercicio (el producto es valioso solo si una contraparte local puede recibirlo, validarlo en campo y traducirlo en política pública).

Recomendaciones específicas para UN-Hábitat HUB Andino. Si el ejercicio se adopta institucionalmente, se proponen tres líneas de acción articuladas. Construir un Observatorio Andino de Asentamientos Informales con cobertura inicial en Cartagena, Bogotá, Medellín, Quito, Lima y La Paz, que integre los productos del modelo, las validaciones de campo y la información comunitaria, con cadencia anual. Capacitar a equipos de Secretarías de Planeación municipales en el uso del flujo, asegurando que la capacidad técnica quede instalada localmente y no concentrada en consultoría externa. Articular con instrumentos de política pública existentes (Programas de Mejoramiento Integral de Barrios en Colombia, programas de regularización del MIDUVI en Ecuador, programas habitacionales del MVCS en Perú), de modo que los productos analíticos alimenten decisiones de inversión y no queden como ejercicios académicos.

Conclusión

El producto se entrega como un flujo reproducible, técnicamente honesto y conscientemente limitado. Su valor reside no en sustituir el trabajo de campo o

el juicio experto sino en focalizarlos, permitiendo que un equipo técnico con recursos limitados (situación habitual en gobiernos locales latinoamericanos) invierta su tiempo allí donde la evidencia preliminar lo justifica. El modelo es defendible, replicable y mejorable, y está pensado bajo la premisa de que la inteligencia artificial aplicada al territorio sirve a la inclusión solamente cuando se diseña con humildad, se acompaña de revisión humana y se inscribe dentro de procesos institucionales más amplios. A esa condición se subordinan todas las decisiones técnicas descritas en este documento.

El repositorio con el código y los productos está disponible en github.com/hperezc/GeoAI-specialist-prueba-tecnica-cartagena, y cualquier consulta puede dirigirse a Héctor Camilo Pérez Contreras al correo hectorcperez21@gmail.com.